INFORME DEL SPRINT 1

Comprensión del negocio y de los datos · Preparación de los datos

Desarrollo de un Sistema Inteligente para clasificar y segmentar tumores cerebrales en resonancias magnéticas (¿para qué?), desplegado en una aplicación web de apoyo académico (¿para dónde?)

Proyecto	Proyecto académico de Redes Neuronales – Opción B (Ingeniería de Sistemas, Inteligencia Artificial)
Metodología	Híbrida: Scrum + CRISP-ML(Q)
Dataset	BRISC 2025 (6.000 resonancias T1 con contraste; clasificación y segmentación)
Periodo del Sprint 1	Trabajo del 1 al 8 de octubre de 2026 · Presentación al docente: lunes 12 de octubre de 2026
Fecha del informe	11 de octubre de 2026
Equipo	Coavoy Cruz Joseph Gabriel (Gerente de Proyecto) · Cuchuyrrumi Mamani Manuel Rodrigo (Scrum Master) · Huallpatuiro Rafaile Brayan · Mamani Acuña Frank Joseph (Equipo de desarrollo)
Docente revisor	Ing. Hugo Espetia Huamanga
Repositorio	https://github.com/Calamar49/CNN-BRISC
Tablero Scrum	https://trello.com/b/swXjkoyS/product-backlog-proyecto-redes-neuronales-brisc

Es una demostración académica: no es una herramienta de diagnóstico médico.

Contenido

1. Resumen ejecutivo
2. Contexto del proyecto
3. Plan del Sprint 1
4. Trabajo realizado
   4.1 HU01 · Definir el problema y el alcance
   4.2 HU02 · Descargar y explorar BRISC
   4.3 HU03 · Preparar los datos y definir la partición
   4.4 HU04 · Presentación del Sprint 1
5. Hallazgos y decisiones técnicas
6. Calidad y verificación
7. Cambios respecto al plan inicial
8. Riesgos y limitaciones
9. Entorno de trabajo y reproducibilidad
10. Alcance: lo que no se hizo en este sprint
11. Plan del Sprint 2 y recomendaciones
Anexo A. Inventario de entregables
Anexo B. Referencias

1. Resumen ejecutivo

El Sprint 1 cubrió las dos primeras fases de CRISP-ML(Q): **comprensión del negocio y de los datos** y **preparación de los datos**. Se completaron las 4 historias de usuario planificadas (HU01 a HU04, 14 puntos). El Acta de Constitución está firmada y el equipo trabaja con un tablero Scrum de 17 historias para todo el proyecto.

Resultados principales:

- **Definición del proyecto:** Acta de Constitución, Product Backlog de 17 historias en Trello con criterios de aceptación, cronograma (Gantt) y las plantillas de gestión del repositorio del docente llenas.
- **Exploración de BRISC 2025 con los datos reales:** 6.000 imágenes (5.000 de entrenamiento y 1.000 de prueba) y 4.793 pares imagen–máscara. Los conteos por clase y partición coinciden con el artículo del dataset (diferencia 0 en las 8 combinaciones).
- **Hallazgos que cambiaron el código:** las máscaras no son estrictamente binarias, las imágenes tienen 183 tamaños distintos y las 1.207 imágenes sin tumor no tienen máscara.
- **Partición reproducible:** 3.999 imágenes de entrenamiento, 1.001 de validación (20 % en cada clase y plano de corte) y 1.000 de prueba oficial intacta, agrupando imágenes casi idénticas para reducir la fuga entre entrenamiento y validación.
- **Cargador de datos** probado con un lote real, y todo el flujo reproducible con dos comandos (`descargar_brisc.py` y `ejecutar_sprint1.py`).
- **Riesgo detectado en el dataset:** entre 113 y 123 de las 1.000 imágenes de la prueba oficial tienen un vecino casi idéntico en el entrenamiento, por lo que el resultado final podría salir algo optimista y debe reportarse con esa advertencia.

> **Aclaración importante:** en este sprint **no se entrenó ningún modelo** y no hay métricas de desempeño (accuracy, recall, IoU). Todos los resultados son de análisis y preparación de datos. El entrenamiento corresponde al Sprint 2.

2. Contexto del proyecto

2.1 Qué se construye y para qué

- **¿Para qué?** Mostrar, con fines académicos, cómo una red neuronal puede apoyar la interpretación de resonancias magnéticas (MRI) cerebrales: identifica el tipo de tumor (glioma, meningioma, tumor de hipófisis o sin tumor) y delimita su contorno.
- **¿Para dónde?** Una aplicación web de demostración en la que quien la usa (el equipo y el docente revisor) sube una MRI y recibe la clase, la probabilidad y la máscara del tumor. Uso académico y de investigación con imágenes T1 con contraste; no está destinado a uso clínico.
- **Sin patrocinador ni Dueño del Producto:** es un proyecto académico; los 4 integrantes definen y priorizan el backlog y el docente solo revisa.

2.2 Metodología híbrida: Scrum + CRISP-ML(Q)

Scrum organiza el trabajo del equipo (backlog, sprints, revisión con el docente y retrospectiva). CRISP-ML(Q) organiza el ciclo de vida del modelo; la "Q" de calidad se aplica con criterios de aceptación en cada historia y con el registro de riesgos. Cada sprint cubre fases de CRISP-ML(Q):

Sprint	Trabajo	Presentación	Fase(s) CRISP-ML(Q)
1	1 – 8 oct 2026	lun 12 oct	Comprensión del negocio y de los datos + preparación de los datos
2	10 – 22 oct 2026	vie 23 oct	Modelado
3	24 – 29 oct 2026	vie 30 oct	Evaluación + despliegue (MLOps básico)

Margen de seguridad: 31 de octubre. Fecha límite del docente: lunes 2 de noviembre de 2026. La fase de monitoreo y mantenimiento se cubre solo en lo básico por el plazo del proyecto (33 días).

2.3 Equipo y roles

Integrante	Rol
Coavoy Cruz Joseph Gabriel	Gerente de Proyecto
Cuchuyrrumi Mamani Manuel Rodrigo	Scrum Master
Huallpatuiro Rafaile Brayan	Equipo de desarrollo
Mamani Acuña Frank Joseph	Equipo de desarrollo

2.4 Metas medibles del proyecto

El Acta de Constitución fija estas metas para el modelo final, medidas **solo sobre la prueba oficial** de BRISC. Se tomaron como referencia los resultados publicados en el artículo del dataset (EfficientNetB0 99,2 % y ResNet50 98,2 % de accuracy; U-Net con mIoU ponderado de 75,7 %), que **no son resultados propios**:

Meta	Valor	Cómo se mide
Accuracy del clasificador	≥ 95 %	Prueba oficial (1.000 imágenes), 4 clases
Recall por clase	≥ 90 % en cada clase	Prueba oficial
IoU de la segmentación	≥ 70 %	Prueba oficial, solo imágenes con tumor

3. Plan del Sprint 1

Meta del sprint: entender el problema y el dataset BRISC a fondo, y dejar los datos listos y particionados sin fuga evidente.

Historia	Fase CRISP-ML(Q)	Gantt	Puntos	Prioridad	Estado
HU01 · Definir el problema y el alcance	Comprensión del negocio y de los datos	1 oct	2	Alta	Terminada
HU02 · Descargar y explorar BRISC (EDA)	Comprensión del negocio y de los datos	2 – 5 oct	5	Alta	Terminada
HU03 · Preparar los datos y definir la partición	Preparación de los datos	6 – 8 oct	5	Alta	Terminada
HU04 · Presentación del Sprint 1	Revisión del sprint (Scrum)	12 oct	2	Media	Terminada
Total			**14**		

La estimación de esfuerzo del Backlog del Sprint (19 tareas) suma **53 horas**; es una estimación propuesta por el equipo en la planificación, no un registro de horas trabajadas. Las tareas por historia fueron:

Tarea	Historia	Descripción	Est. (h)
1.1	HU01	Redactar y revisar el Acta de Constitución (título, ¿para qué?, ¿para dónde?, riesgos, hitos)	6
1.2	HU01	Fijar las metas medibles (accuracy, recall por clase e IoU) con referencia del artículo de BRISC	2
1.3	HU01	Armar el Product Backlog en Trello y el cronograma (Gantt)	4
2.1	HU02	Descargar BRISC en el equipo y preparar el notebook	2
2.2	HU02	Verificar la estructura de carpetas y leer manifest.csv	2
2.3	HU02	Contar imágenes por clase, partición y plano, y compararlas con el artículo	3
2.4	HU02	Medir dimensiones de imagen y porcentaje del tumor en cada máscara	3
2.5	HU02	Galería de imagen con máscara por clase	2
2.6	HU02	Confirmar si las imágenes sin tumor tienen máscara y la licencia del dataset	1
2.7	HU02	Resumir los hallazgos del análisis exploratorio	2
3.1	HU03	Verificar archivos corruptos y pares imagen-máscara	3
3.2	HU03	Agrupar imágenes muy parecidas (hash perceptual) para reducir la fuga entre particiones	4
3.3	HU03	Definir la partición de entrenamiento y validación (estratificada por clase y plano, semilla fija)	3
3.4	HU03	Guardar las listas de la partición y versionarlas en GitHub	1
3.5	HU03	Escribir el cargador de datos y probar que carga un lote	4
3.6	HU03	Fijar el preprocesamiento (tamaño de entrada y normalización)	2
4.1	HU04	Armar las diapositivas de la revisión del Sprint 1	5
4.2	HU04	Hacer un ensayo de la presentación	2
4.3	HU04	Hacer la retrospectiva del Sprint 1	2

4. Trabajo realizado

4.1 HU01 · Definir el problema y el alcance

Entregables de la historia:

- **Acta de Constitución** (firmada): título del proyecto con su ¿para qué? y ¿para dónde?, propósito, alcance (qué incluye y qué no), restricciones, metas medibles, riesgos y oportunidades, hitos, presupuesto y equipo. No hay patrocinador ni Dueño del Producto; el docente es el revisor.
- **Product Backlog en Trello** con 17 historias (HU01 a HU17) organizadas en 4 épicas: EP1 Entender el negocio y los datos, EP2 Modelar, EP3 Evaluación y despliegue (MLOps) y EP4 Informe y presentación final. Cada tarjeta trae historia de usuario, prioridad, estimación en puntos, dependencias, fase CRISP-ML(Q) y un checklist de criterios de aceptación. Además hay tarjetas de proyecto y metodología, y una de meta del sprint.
- **Cronograma:** diagrama de Gantt y archivo CSV para la herramienta de cronogramas, con los tres sprints y sus presentaciones.
- **Plantillas de gestión llenas** (formato del repositorio del docente): Backlog del Producto, Registro de Interesados, Planificación de Lanzamiento, Backlog Detallado, Backlog del Sprint, Cronograma de hitos, Presupuesto (costo programado de S/ 0: dataset, cómputo y alojamiento con planes gratuitos), Registro de Riesgos, Informe de Estado, Minuta, Registro de Impedimentos y las presentaciones de revisión y retrospectiva.

- **Revisión general del Acta contra el artículo de BRISC:** se corrigieron la licencia, las referencias de resultados y el presupuesto, para que no queden datos inventados ni contradicciones.

4.2 HU02 · Descargar y explorar BRISC

Qué es BRISC 2025

BRISC 2025 es un dataset público de resonancias magnéticas cerebrales **T1 con contraste**: 6.000 cortes en tres planos (axial, coronal y sagital) y cuatro clases (glioma, meningioma, tumor de hipófisis y sin tumor). Incluye una tarea de clasificación y una de segmentación, con una partición oficial de 5.000 imágenes de entrenamiento y 1.000 de prueba. Según el artículo, deriva de datasets públicos previos (Nickparvar, Cheng, SARTAJ y Br35H). **Licencia: CC BY 4.0** (metadatos de Kaggle), por lo que hay que citar a los autores. Los nombres de archivo siguen el patrón `brisc2025_<partición>_<índice>_<código>_<plano>_<secuencia>.jpg`.

Descarga y estructura

El dataset se descargó con el script `descargar_brisc.py` a una carpeta fuera de OneDrive (`~/datasets/brisc2025`), de unos 277 MB y 15.586 archivos de imagen. El notebook verificó la estructura: carpetas `classification_task` y `segmentation_task` más el archivo `manifest.csv` (con su suma SHA-256 por archivo).

Carpeta	Entrenamiento	Prueba
classification_task / glioma	1.147	254
classification_task / meningioma	1.329	306
classification_task / pituitary (hipófisis)	1.457	300
classification_task / no_tumor (sin tumor)	1.067	140
segmentation_task / images	3.933	860
segmentation_task / masks	3.933	860

Conteos por clase y plano de corte

Los conteos por clase y partición son **idénticos a los del artículo** (diferencia 0 en las 8 combinaciones):

Clase	Entrenamiento	Prueba	Total	Axial	Coronal	Sagital
Glioma	1.147	254	1.401	479	511	411
Meningioma	1.329	306	1.635	560	512	563
Tumor de hipófisis	1.457	300	1.757	550	600	607
Sin tumor	1.067	140	1.207	404	358	445
Total	**5.000**	**1.000**	**6.000**	**1.993**	**1.981**	**2.026**

Los conteos por **plano de corte** difieren levemente de la Tabla 2 del artículo. Se usan los valores observados:

Partición / plano	Artículo	Observado	Diferencia
Entrenamiento · axial	1.550	1.595	+45
Entrenamiento · coronal	1.660	1.676	+16
Entrenamiento · sagital	1.790	1.729	−61
Prueba · axial	387	398	+11
Prueba · coronal	316	305	−11
Prueba · sagital	297	297	0

El código de clase en el nombre del archivo es `gl` (glioma), `me` (meningioma), `pi` (hipófisis) y `no` (sin tumor); el README del dataset menciona `nt` para sin tumor, pero los archivos reales usan `no`. Cada código corresponde a una sola clase. La composición está levemente desbalanceada (de 1.207 a 1.757 imágenes por clase).

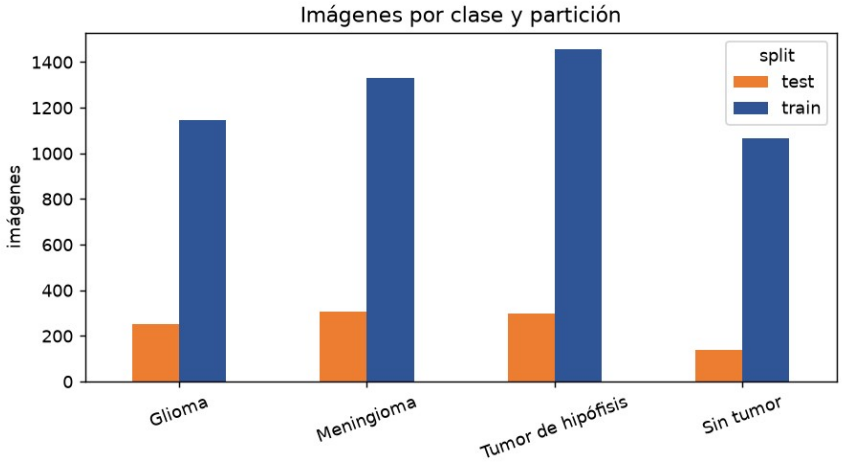


Figura 1. Imágenes por clase y partición oficial.

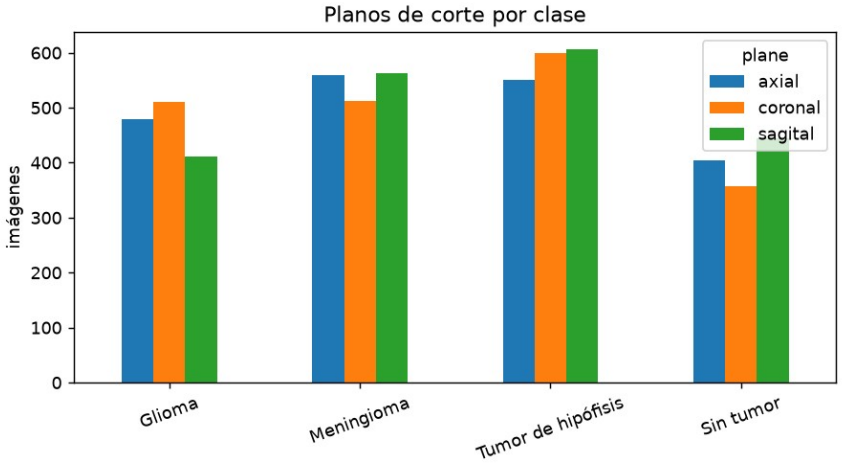


Figura 2. Planos de corte por clase.

Segmentación: pares imagen–máscara

- Hay **4.793 pares** imagen–máscara completos (3.933 de entrenamiento y 860 de prueba), igual que el artículo. No hay máscaras sin imagen ni imágenes sin máscara dentro de la tarea de segmentación.
- Distribución de los pares por clase: glioma 1.401, meningioma 1.635 y tumor de hipófisis 1.757.
- **Las 1.207 imágenes sin tumor no tienen máscara** (0 de 1.207). La página de Kaggle habla de 6.000 imágenes y máscaras, pero los archivos confirman lo que decía el artículo. Por eso la segmentación se entrena y se evalúa solo con las 4.793 imágenes con tumor.
- Ninguna máscara está vacía.

Formato de las máscaras y tamaño de las imágenes

- **Máscaras no binarias:** las 4.793 máscaras (archivos PNG) contienen valores intermedios (normalmente de 0 a 6 y, en algunos casos, valores altos como 250), probablemente por remuestreo. No es un error de los datos, pero obliga a binarizar: se consideran tumor los píxeles > 127.
- **Tamaños variables:** hay 183 combinaciones de ancho × alto. La más común es 512×512 (4.881 imágenes); siguen 369×369 (363) y 216×369 (354). Las máscaras son de 512×512 en 4.504 casos, 256×256 en 30 y 225×225 en 15 (entre las tres más frecuentes). No hay una relación de aspecto única.

Tamaño del tumor

El tumor ocupa una fracción muy pequeña de la imagen (en mediana, entre el 0,9 % y el 1,7 %), de modo que en la segmentación el fondo domina ampliamente. Esto condiciona la elección de la función de pérdida en el Sprint 2.

Clase	Pares	Media	Mediana	Mínimo	Máximo
Glioma	1.401	1,87 %	1,52 %	0,05 %	9,77 %
Meningioma	1.635	2,25 %	1,74 %	0,01 %	17,35 %
Tumor de hipófisis	1.757	1,04 %	0,86 %	0,06 %	6,49 %

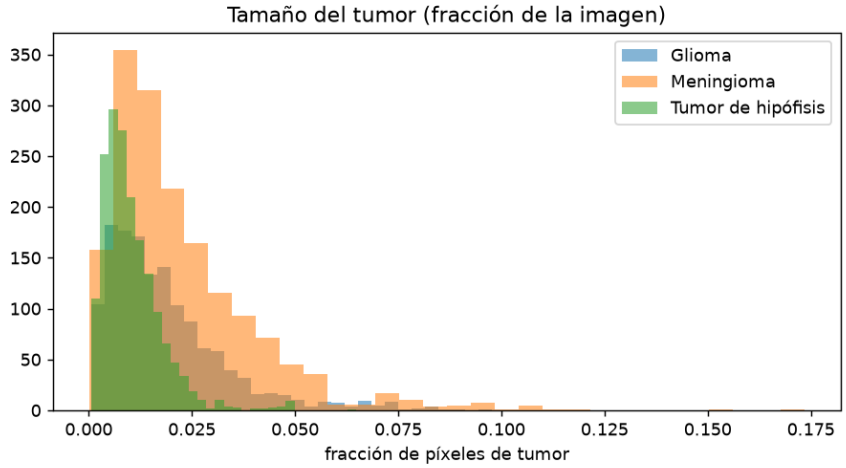


Figura 3. Distribución del tamaño del tumor (fracción de píxeles de la imagen) por clase.

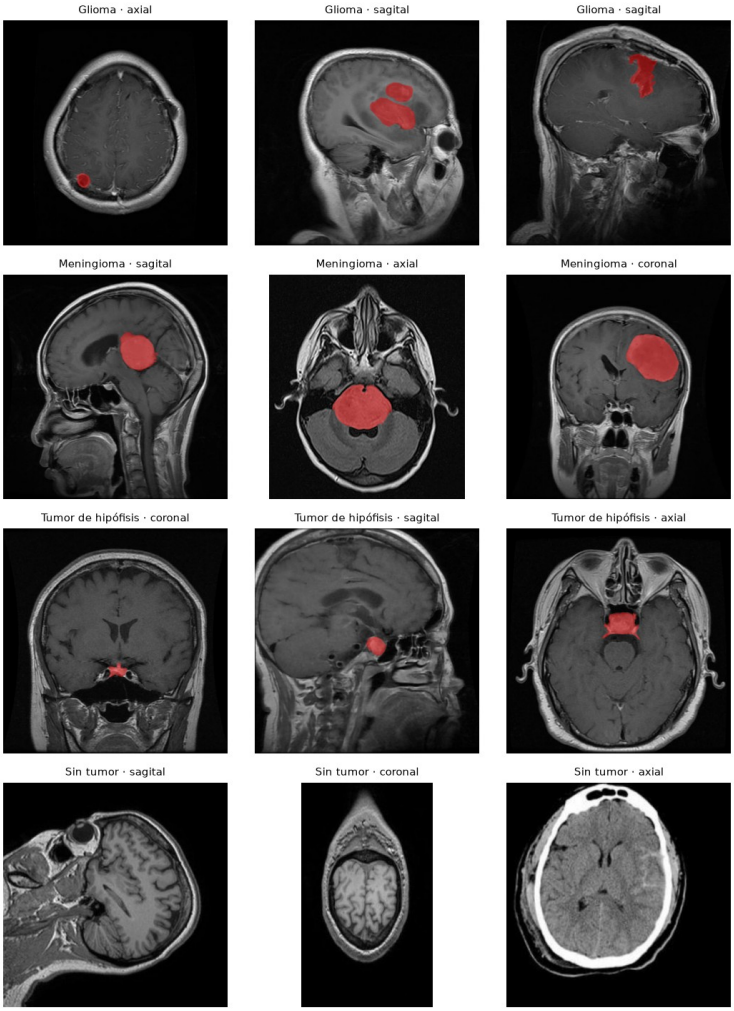


Figura 4. Imagen y máscara (en rojo) por clase y plano; la fila inferior es la clase sin tumor, que no tiene máscara.

manifest.csv y duplicados

El manifest tiene 16 columnas (ruta, nombre, tarea, partición, clase, plano, secuencia, indicador de máscara, imagen vinculada, ancho, alto, tamaño y SHA-256). Contiene 6.000 imágenes de clasificación; su tarea de segmentación repite las mismas imágenes, por lo que un conteo de duplicados sobre todo el archivo es engañoso (la primera versión del notebook reportaba 9.639 hashes repetidos por ese motivo). Corregido el filtro, **96 archivos de clasificación tienen un SHA-256 repetido** (duplicados exactos) y **7 de esos hashes aparecen tanto en entrenamiento como en prueba**.

Limitaciones registradas

- El dataset no trae ID de paciente: cortes de un mismo paciente pueden estar en particiones distintas.
- Solo hay imágenes T1 con contraste: los modelos pueden rendir peor con otras secuencias (T2, sin contraste) o con otros equipos.
- La clase sin tumor incluye cerebros sanos y lesiones no neoplásicas (según el artículo).

4.3 HU03 · Preparar los datos y definir la partición

Integridad de los datos

Se abrieron y verificaron las 6.000 imágenes y las 4.793 máscaras, y se comprobó que cada máscara tuviera el mismo tamaño que su imagen. Resultado: **0 archivos corruptos, 0 máscaras sin imagen, 0 imágenes de segmentación sin máscara, 0 máscaras vacías y 0 diferencias de tamaño**. La prueba oficial (1.000 imágenes) queda reservada: no se usa para entrenar ni para ajustar, y el notebook comprueba que no cambie.

Por qué una partición propia de validación

BRISC solo trae entrenamiento (5.000) y prueba (1.000). En el Sprint 2 se compararán varias arquitecturas e hiperparámetros, y esas decisiones necesitan medirse con datos que el modelo no vio. Si se usara la prueba oficial para elegir, dejaría de ser una medida honesta del resultado final. Por eso la validación se separa del entrenamiento oficial, y la prueba se usa una sola vez, al final.

Agrupación de imágenes casi idénticas (hash perceptual)

Como BRISC no trae ID de paciente, una partición aleatoria podría mandar cortes casi idénticos del mismo paciente a entrenamiento y a validación, inflando las métricas. Para reducir ese riesgo se calcula un **dHash de 256 bits** de cada imagen (diferencias entre píxeles vecinos de una versión reducida a 17×16), se agrupan las imágenes cuya distancia de Hamming es menor o igual que un umbral (algoritmo union-find) y cada grupo completo se asigna a un único lado de la partición.

El umbral no se fijó a ciegas. La primera versión usaba un hash de 64 bits con umbral 6 y, al ejecutarla con los datos reales, formó un grupo de 1.933 imágenes distintas (inútil para partir los datos). Se midió entonces la distancia de cada imagen a su vecino más cercano dentro del entrenamiento (percentiles 5/25/50/75/95 = 21/31/40/55/77 bits de 256) y se compararon varios umbrales:

Umbral (de 256 bits)	Grupos	Tamaño del mayor	Grupos con más de 1 imagen
8	4.952	3	42
16 (elegido)	**4.938**	**3**	**55**
24	4.727	6	217
32	4.077	11	548

Con el umbral 16 las 5.000 imágenes de entrenamiento quedan en 4.938 grupos; 55 grupos tienen más de una imagen y el mayor tiene 3. Es un criterio conservador: agrupa solo imágenes casi idénticas.

Fuga entre las particiones oficiales

También se midió, solo como información, cuántas imágenes de la **prueba oficial** tienen un vecino casi idéntico en el entrenamiento oficial: **113 de 1.000 según el dHash** (distancia ≤ 16) y **123 de 1.000 según la correlación de miniaturas de 32×32** (≥ 0,98). Esto no se puede corregir (la prueba oficial no se toca), pero hay que declararlo al reportar el resultado final: parte de la prueba se parece al entrenamiento.

Partición entrenamiento / validación

Se usó `StratifiedGroupKFold` de scikit-learn (5 pliegues, uno de ellos como validación, semilla 42), estratificando por **clase y plano de corte** y respetando los grupos. El notebook comprueba con aserciones que ningún grupo quede repartido entre entrenamiento y validación y que la prueba oficial no haya cambiado.

Clase	Entrenamiento	Validación	Prueba oficial	Total
Glioma	917	230	254	1.401
Meningioma	1.063	266	306	1.635
Tumor de hipófisis	1.166	291	300	1.757
Sin tumor	853	214	140	1.207
Total	**3.999**	**1.001**	**1.000**	**6.000**

Plano	Entrenamiento	Validación	Prueba oficial
Axial	1.275	320	398
Coronal	1.341	335	305
Sagital	1.383	346	297

La proporción de validación es de 20 % en cada clase (0,200 a 0,201) y en cada plano (0,200 a 0,201).

Preprocesamiento y cargador de datos

El cargador (`BriscDataset`) devuelve la imagen normalizada (3 × 256 × 256), la clase, la máscara y un indicador `tiene_mascara`. Decisiones fijadas:

Aspecto	Decisión	Motivo
Tamaño de entrada	256 × 256 (puede bajarse a 224 para transfer learning)	Equilibrio entre detalle y memoria de GPU (6 GB)
Imágenes no cuadradas	Se rellenan con ceros a cuadrado, centradas, y luego se redimensionan	Hay 183 tamaños distintos; así no se deforman
Interpolación	Bilineal para imágenes, *nearest* para máscaras	Las máscaras no deben mezclar valores
Máscaras	Se binarizan con umbral > 127	Traen valores intermedios por remuestreo
Imágenes sin tumor	Máscara vacía e indicador `tiene_mascara = False`	No tienen máscara; así se puede ignorar su pérdida de segmentación
Normalización	Media (0,485; 0,456; 0,406) y desvío (0,229; 0,224; 0,225) de ImageNet	Compatible con transfer learning
Aumento de datos	No se define aún	Se ajusta en el Sprint 2 (HU08)
Reproducibilidad	Semilla 42; listas de partición guardadas en CSV	Mismos conjuntos en todas las ejecuciones

El cargador se probó con un lote real de 8 imágenes (formas 8×3×256×256 para imágenes y 8×1×256×256 para máscaras) usando `DataLoader` de PyTorch.

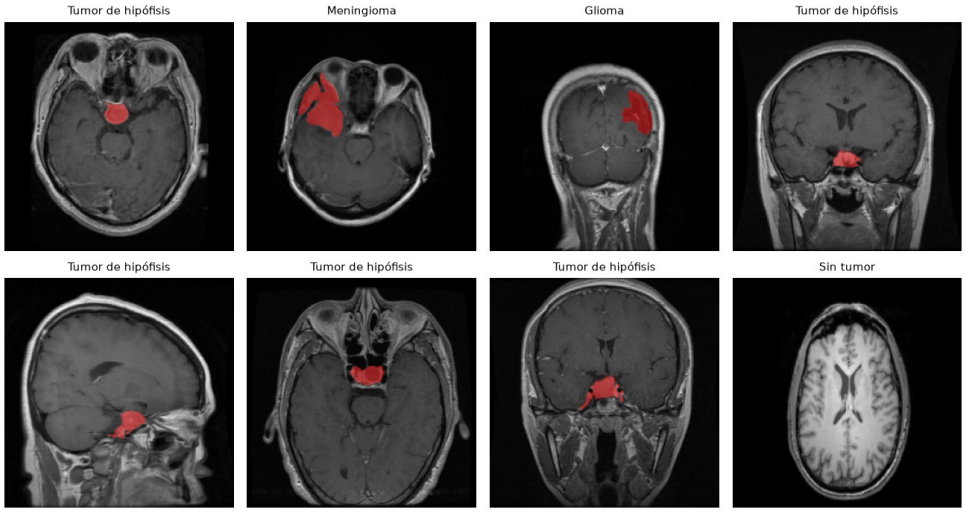


Figura 5. Lote de prueba producido por el cargador (imagen normalizada y máscara superpuesta; las imágenes sin tumor no muestran máscara).

Archivos generados

- `particion/particion_train.csv`, `particion_val.csv`, `particion_test.csv` y `particion_completa.csv` (archivo, ruta, clase, plano, partición, grupo y máscara).
- `particion/config_preparacion.json` (semilla, umbrales, tamaño de entrada, normalización, conteos y número de grupos).

- `eda_resumen.json`, `figuras_eda/` y `lote_de_prueba.png`, además de copias de los notebooks con todas sus salidas en `notebooks_ejecutados/`.

4.4 HU04 · Presentación del Sprint 1

- **Revisión del Sprint** (13 diapositivas, para el lunes 12 de octubre): meta del sprint, el proyecto, el dataset verificado, historias del sprint, demostración con las figuras reales (conteos, imagen y máscara, tamaño del tumor), hallazgos, riesgos y plan del Sprint 2.
- **Retrospectiva del Sprint** (7 diapositivas): plantilla del docente con las preguntas (qué aprendimos, qué estamos haciendo bien, qué podemos mejorar, personas y relaciones). Las respuestas corresponden al equipo y se registran en la reunión de retrospectiva.
- El **Informe de Estado** y la **Minuta de Reunión** del periodo también quedaron llenos con el avance del sprint; los pocos campos de datos que solo conoce el equipo (por ejemplo, fecha y lugar de la reunión o gastos registrados) los completa el equipo.

5. Hallazgos y decisiones técnicas

Hallazgo (con datos reales)	Decisión
Los conteos por clase y partición coinciden con el artículo; los de plano difieren levemente	Usar los conteos observados y documentar la diferencia
Las 1.207 imágenes sin tumor no tienen máscara (4.793 pares)	Entrenar y evaluar la segmentación solo con imágenes con tumor; en un modelo multitarea, máscara vacía y pérdida de segmentación ignorada
Máscaras con valores intermedios (0–6 y 250/255)	Binarizar con umbral > 127 en el análisis y en el cargador
183 tamaños de imagen; no hay una única relación de aspecto	Rellenar a cuadrado sin deformar y redimensionar a 256×256
El tumor ocupa en mediana entre 0,9 % y 1,7 % de la imagen	Considerar pérdidas robustas al desbalance en la segmentación (Dice o focal) y métricas por clase en el Sprint 2
Sin ID de paciente; un hash de 64 bits con umbral 6 agrupaba mal (grupo de 1.933)	dHash de 256 bits con umbral 16, elegido midiendo la distancia al vecino más cercano
113–123 imágenes de prueba tienen un vecino casi idéntico en entrenamiento	No tocar la prueba; reportar el resultado final con esta advertencia
96 archivos con SHA-256 repetido (7 entre entrenamiento y prueba)	Documentar; la agrupación por hash los mantiene del mismo lado dentro del entrenamiento
Licencia CC BY 4.0	Citar a los autores de BRISC y de las fuentes originales en el informe final
La clase sin tumor incluye cerebros sanos y lesiones no neoplásicas	Mencionarlo al interpretar los errores de clasificación

6. Calidad y verificación

- **Criterios de aceptación:** las 17 historias tienen criterios en Trello (la "Q" de CRISP-ML(Q)). Los de HU01, HU02 y HU03 están marcados como cumplidos, con comentarios que documentan la evidencia.
- **Desarrollo de los notebooks en dos pasos:** primero se probaron con un dataset sintético que imita la estructura descrita en el artículo y después se ejecutaron con BRISC real. La segunda ejecución destapó tres defectos que la prueba sintética no podía mostrar; se corrigieron y se volvió a ejecutar todo:
  - Las máscaras no binarias se marcaban como "problema" en las 4.793 (ahora se informan y se binarizan).
  - El chequeo de duplicados del manifest contaba la tarea de segmentación (ahora filtra solo clasificación).

    - El umbral del hash perceptual era demasiado laxo (ahora se eligió midiendo las distancias).
- **Comparación con el artículo:** conteos por clase, partición y pares de segmentación contrastados con las Tablas 1 y 2 del artículo de BRISC; las diferencias de plano quedaron registradas.
- **Revisión del Acta de Constitución:** se contrastó con el artículo y se corrigieron la licencia, las referencias de resultados y el presupuesto; la licencia se verificó en los metadatos de Kaggle.
- **Reproducibilidad:** los notebooks usan semilla fija y se ejecutan de punta a punta con `python ejecutar_sprint1.py`.

7. Cambios respecto al plan inicial

Cambio	Detalle
Presentación del Sprint 1	Se movió del viernes 9 al lunes 12 de octubre por decisión del equipo; los Sprints 2 y 3 no cambian (23 y 30 de octubre).
Dónde se ejecuta	Los notebooks se pensaron para Kaggle Notebooks y el equipo decidió ejecutarlos **en local**. Se ajustaron scripts, READMEs, el Acta de Constitución, el Registro de Riesgos y las presentaciones. El dataset se guarda fuera de OneDrive para no sincronizar unas 15.000 imágenes.
Estimaciones de cómputo	El Acta y el Registro de Riesgos asumían GPU gratuita en la nube; ahora indican una GPU local (NVIDIA RTX 4050 de 6 GB) con Google Colab como respaldo.
Redacción de supuestos	Tras ejecutar con datos reales, los supuestos "a confirmar" (imágenes sin máscara, licencia, partición) pasaron a hechos verificados en los documentos.

8. Riesgos y limitaciones

Estado del Registro de Riesgos al cierre del Sprint 1 (la calificación de probabilidad e impacto es una propuesta del equipo):

ID	Riesgo	Estado y novedad del Sprint 1
R01	Fuga entre pacientes: sin ID de paciente, una validación aleatoria puede dar métricas infladas	Activo. Mitigado en la validación con grupos por hash; se detectó además que 113–123 imágenes de prueba se parecen a entrenamiento.
R02	Cambio de dominio: peor desempeño con T2, sin contraste u otros centros	Activo. BRISC solo contiene T1 con contraste; avisarlo en la aplicación.
R03	Las imágenes sin tumor no tienen máscara	Confirmado (0 de 1.207). Mitigación aplicada en el diseño de datos.
R04	Arquitecturas inestables en el artículo (Xception, DenseNet y MobileNetV2)	Activo. Partir de EfficientNet o ResNet y repetir entrenamientos con distintas semillas.
R05	Modelos demasiado pesados para correr en el navegador	Activo. Se decide en el Sprint 3 (modelos livianos o cuantizados; API gratuita si no alcanza).
R06	Falta de GPU o sobreajuste	Activo. GPU local de 6 GB; PyTorch instalado es solo CPU y requiere la versión CUDA.
R07	Retraso del cronograma (Sprint 2 es el más largo; margen final de un día)	Activo. El Sprint 1 cerró según lo planificado.
R08	Uso indebido de la demo como herramienta de diagnóstico	Activo. Aviso visible de demostración académica.

9. Entorno de trabajo y reproducibilidad

Elemento	Detalle
Equipo de ejecución	Windows 11, Python 3.13, GPU NVIDIA RTX 4050 de 6 GB (PyTorch instalado con soporte solo CPU)
Bibliotecas del Sprint 1	numpy, pandas, matplotlib, pillow, scikit-learn, jupyter, nbconvert, ipykernel y kaggle (ver `requirements.txt`)
Dataset	`C:\Users\<usuario>\datasets\brisc2025` (fuera de OneDrive); variable `BRISC_ROOT` para usar otra ruta
Repositorio	https://github.com/Calamar49/CNN-BRISC (documentos de gestión, notebooks y scripts; sin dataset ni salidas pesadas)
Tablero Scrum	Trello: Product Backlog, Sprint 1, Sprint 2, Sprint 3, En progreso y Terminado

Para reproducir el Sprint 1, desde la carpeta `03. Implementacion/Sprint 1 - Notebooks`:

`pip install -r requirements.txt` → `python descargar_brisc.py` → `python ejecutar_sprint1.py`

La carpeta `salida_sprint1/` se regenera en cada ejecución y no se sube a Git. El dataset se descarga sin iniciar sesión en Kaggle.

10. Alcance: lo que no se hizo en este sprint

- **No se entrenó ningún modelo** ni se calcularon métricas de desempeño; las metas del Acta (accuracy, recall e IoU) aún no se han medido.
- No se definió el aumento de datos (se ajusta en HU08) ni se eligió arquitectura ni framework de entrenamiento definitivo (decisión de HU05).
- **Pendientes menores de gestión:** completar los campos del equipo en la Retrospectiva, en el Informe de Estado y en la Minuta, y llenar el Cronograma detallado (archivo `.mpp` de la plantilla, que sigue vacío).

11. Plan del Sprint 2 y recomendaciones

Historia	Fechas (Gantt)	Puntos	Depende de
HU05 · Seleccionar arquitectura y entrenar el modelo base	12 – 13 oct	3	HU03
HU06 · Entrenar el clasificador de tipo de tumor	14 – 18 oct	8	HU05
HU07 · Entrenar el modelo de segmentación U-Net	14 – 18 oct	8	HU05
HU08 · Ajustar hiperparámetros y mejorar los modelos	19 – 21 oct	5	HU06, HU07
HU09 · Registrar y comparar experimentos	21 – 22 oct	3	HU08
HU10 · Presentación del Sprint 2	23 oct	2	HU09
HU11 · (Opcional) Modelo multitarea	solo si el cronograma lo permite	8	HU09

Recomendaciones para el Sprint 2 que salen de lo aprendido en el Sprint 1:

1. **Instalar PyTorch con soporte CUDA** para usar la GPU (la instalación actual es solo CPU) y decidir el framework y el formato de exportación del modelo.
2. **Partir de arquitecturas con respaldo** (EfficientNetB0 y ResNet50 en el artículo) y repetir los entrenamientos con 2 o 3 semillas por la inestabilidad reportada.

3. **Segmentación solo con imágenes con tumor** (3.933 de entrenamiento oficial) y una pérdida adecuada al desbalance de píxeles (el tumor es del 1–2 % de la imagen).
4. **Elegir en validación, evaluar una vez en la prueba.** Una vez elegida la mejor configuración se puede reentrenar con los 5.000 del entrenamiento oficial, fijando el número de épocas obtenido en validación, y evaluar una sola vez en la prueba oficial (HU12). Es opcional.
5. **Guardar por experimento** la curva de entrenamiento, la época óptima, la semilla y las métricas por clase (HU09).
6. **Reportar la advertencia de la prueba:** 113–123 imágenes de prueba tienen un vecino casi idéntico en entrenamiento.

Anexo A. Inventario de entregables

Carpeta	Archivos
01. Inicio	Acta de Constitución, Backlog del Producto, Registro de Interesados, Planificación de Lanzamiento
02. Planificacion	Backlog Detallado del Producto, Backlog del Sprint (hoja Sprint 1), Cronograma de alto nivel – Hitos, Cronograma detallado (.mpp, sin llenar), Presupuesto del Proyecto, Registro de Riesgos, CSV del Gantt
03. Implementacion	Informe de Estado del Proyecto, Minuta de Reunión, Registro de Impedimentos, Informe del Sprint 1 (este documento) y la carpeta Sprint 1 - Notebooks (dos notebooks, descargar_brisc.py, ejecutar_sprint1.py y README)
04. Revision y retrospectiva	Revisión del Sprint (13 diapositivas) y Retrospectiva del Sprint (7 diapositivas)
05. Lanzamiento y 06. Cierre	Plantillas sin llenar; se usan al final del proyecto
Raíz del repositorio	README.md, requirements.txt y .gitignore

Anexo B. Referencias

- Dataset BRISC 2025 (Kaggle): https://www.kaggle.com/datasets/briscdataset/brisc2025/ · Licencia CC BY 4.0 (metadatos de Kaggle).
- Artículo del dataset: https://arxiv.org/abs/2506.14318
- Repositorio del proyecto: https://github.com/Calamar49/CNN-BRISC
- Tablero Scrum (Trello): https://trello.com/b/swXjkoyS/product-backlog-proyecto-redes-neuronales-brisc
- Plantillas de gestión: repositorio del docente https://github.com/hespetia/gestion-proyectos