INFORME FINAL DEL PROYECTO

Clasificación y segmentación de tumores cerebrales — Sprints 1 a 3

Desarrollo de un Sistema Inteligente para clasificar y segmentar tumores cerebrales en resonancias magnéticas, desplegado en un prototipo de sistema web de apoyo al diagnóstico (demostración académica).

Proyecto	Redes Neuronales – Opción B (Ingeniería de Sistemas, Inteligencia Artificial)
Metodología	Híbrida: Scrum + CRISP-ML(Q)
Sprint 3	Evaluación, despliegue y cierre · presentación final 30 oct 2026
Docente revisor	Ing. Hugo Espetia Huamanga
Dataset	BRISC 2025 (Kaggle, CC BY 4.0) — 6.000 imágenes, 4.793 máscaras
Repositorio	github.com/Calamar49/CNN-BRISC

Integrante	Rol
Coavoy Cruz Joseph Gabriel	Gerente de Proyecto
Cuchuyrrumi Mamani Manuel Rodrigo	Scrum Master
Huallpatuiro Rafaile Brayan	Equipo de desarrollo
Mamani Acuña Frank Joseph	Equipo de desarrollo

Demostración académica; no es una herramienta de diagnóstico médico. Todos los números provienen de mediciones reales del equipo (ver evaluacion_prueba.json y registro_modelos.json); las cifras del artículo de BRISC se citan como tales. La prueba oficial se evaluó una sola vez.

1. Resumen ejecutivo

El proyecto construyó un sistema que, dada una resonancia magnética cerebral (T1 con contraste), **clasifica** el tipo de tumor (glioma, meningioma, tumor de hipófisis o sin tumor) y **segmenta** su contorno, y lo mostró en un **prototipo de sistema web de apoyo al diagnóstico**. El trabajo siguió Scrum + CRISP-ML(Q) en tres sprints: comprensión del negocio y los datos (Sprint 1), modelado (Sprint 2) y evaluación y despliegue (Sprint 3).

- **Evaluación en la prueba oficial (HU12), una sola vez:** el clasificador desplegado alcanzó **99.10 % de accuracy** y el segmentador **80.10 % de IoU** (87.07 % de Dice). Las **tres metas del acta** (accuracy ≥ 95 %, recall ≥ 90 % por clase, IoU ≥ 70 %) **se cumplen**.
- **Despliegue (HU13):** un prototipo de sistema clínico con el flujo completo de apoyo al diagnóstico en neuro-oncología (inicio de sesión, casos, subir una resonancia, resultado con contorno, revisión del médico e informe del caso), que funciona en local y sin internet.
- **MLOps básico (HU14):** modelos exportados a ONNX y versionados con SHA-256, registro de modelos y de datos, etiquetas de Git y monitoreo de predicciones en la aplicación.

> **Honestidad:** la prueba oficial no se usó para elegir nada; el modelo desplegado se eligió por validación (semilla 2024). Se reporta el efecto de las imágenes de prueba parecidas al entrenamiento y las limitaciones. **No es un diagnóstico médico.**

2. Comprensión del negocio

Objetivo: apoyar la lectura de resonancias en neuro-oncología con un sistema que sugiere el tipo de tumor y marca su contorno, como **apoyo al diagnóstico** (nunca en reemplazo del médico). No hay cliente real ni datos de pacientes reales: es una demostración académica. Metas del acta (sobre la prueba oficial): accuracy ≥ 95 %, recall ≥ 90 % por clase e IoU ≥ 70 %.

3. Comprensión y preparación de los datos (Sprint 1)

Dataset BRISC 2025 (CC BY 4.0): 6.000 imágenes T1 con contraste y 4.793 máscaras de tumor. Se preparó a 256×256 en gris con normalización de ImageNet y una **partición propia (semilla 42): 3.999 entrenamiento / 1.001 validación / 1.000 prueba oficial**, agrupando por hash perceptual para evitar fuga evidente. La prueba oficial se dejó intacta para evaluarla una sola vez al final.

4. Modelado (Sprint 2)

Se compararon dos arquitecturas de clasificación con transfer learning (EfficientNetB0 y ResNet50) y una U-Net con encoder ResNet34 para segmentación, con 13 entrenamientos registrados (ajuste de hiperparámetros y 3 semillas). Configuraciones elegidas por **validación**: EfficientNetB0 (lote 64) y U-Net (lr 1e-4).

Tarea	Modelo elegido	Validación (Sprint 2, 3 semillas)
Clasificación	EfficientNetB0 (lote 64)	recall medio 99,57 % ± 0,15 %
Segmentación	U-Net (encoder ResNet34, lr 1e-4)	IoU 80,12 % ± 0,33 %

5. Evaluación en la prueba oficial (HU12)

La prueba oficial (1000 imágenes de clasificación, 860 con máscara) se evaluó **una sola vez**. Siguiendo el plan, se evaluaron los **6 puntos de control del Sprint 2** (3 semillas × 2 tareas) y se reporta el promedio ± desvío; el **modelo desplegado** es el mejor por validación (semilla 2024). No se cambió nada después de ver los números.

5.1 Resultados frente a las metas del acta

Métrica	Meta del acta	Prueba oficial (desplegado)	Resultado
Accuracy (clasificación)	≥ 95 %	99.10 %	Cumple ✓
Recall por clase (mínimo)	≥ 90 %	97.24 % (glioma)	Cumple ✓
IoU (segmentación)	≥ 70 %	80.10 %	Cumple ✓

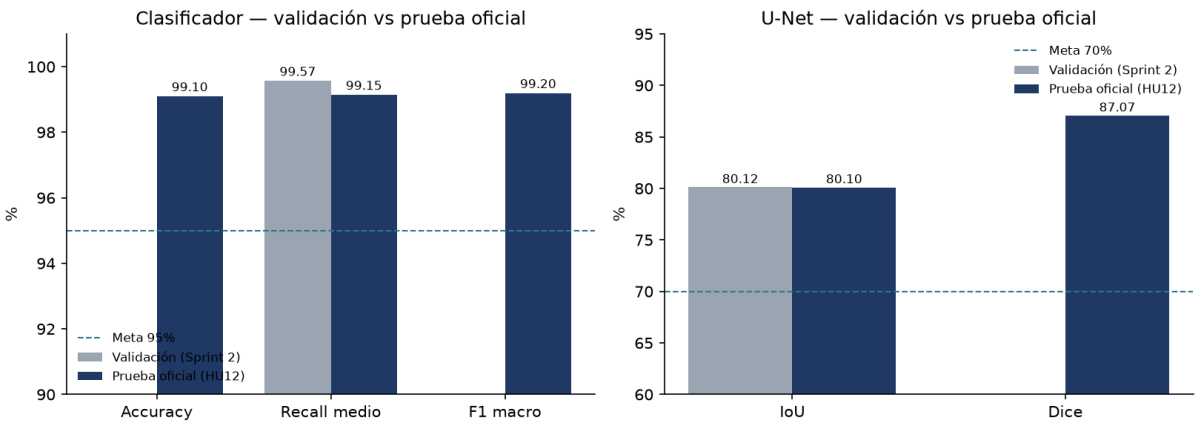


Figura 1. Validación (Sprint 2) frente a la prueba oficial (HU12). El desempeño en prueba es muy cercano al de validación: el modelo generaliza y no colapsa por sobreajuste.

El clasificador promedió **99.17 % ± 0.12 %** de accuracy sobre las 3 semillas, y la U-Net **79.90 % ± 0.19 %** de IoU. La variabilidad entre semillas es pequeña.

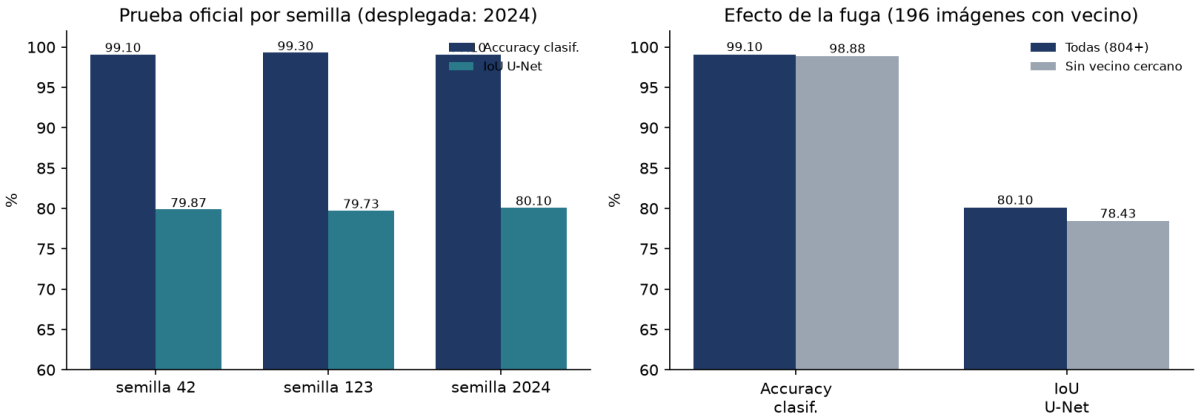


Figura 2. Izquierda: resultado por cada una de las 3 semillas (la desplegada es la 2024). Derecha: efecto del subconjunto sin vecino cercano al entrenamiento.

5.2 Clasificación: recall por clase y matriz de confusión

Clase	Recall en la prueba
Glioma	97.24 %
Meningioma	99.67 %

Hipófisis	99.67 %
Sin tumor	100.00 %

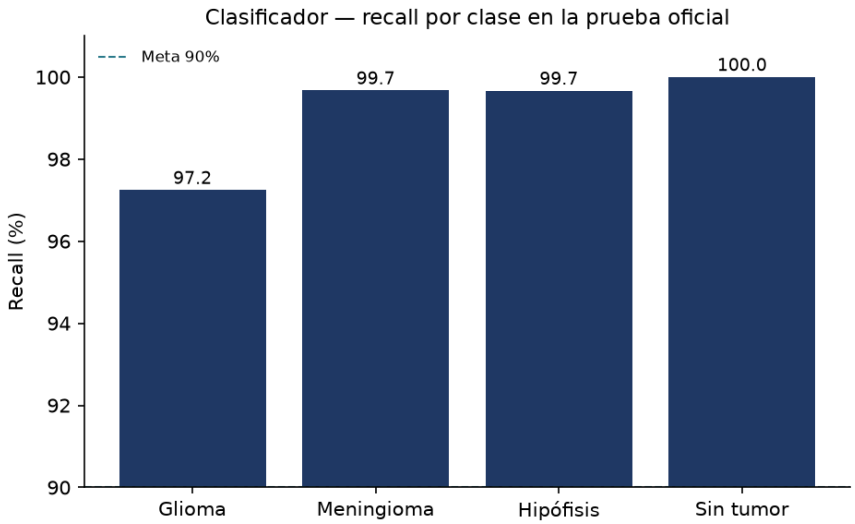


Figura 3. Recall por clase en la prueba oficial; todas superan la meta de 90 %. El glioma es la clase más difícil.

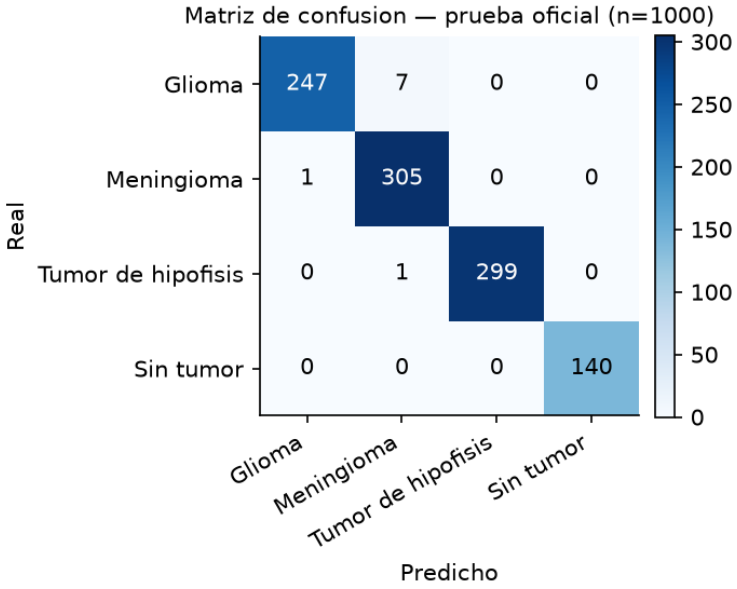


Figura 4. Matriz de confusión real sobre las 1.000 imágenes de la prueba oficial.



Figura 5. Ejemplos reales de aciertos y errores de clasificación (salida del modelo, sin retocar).

5.3 Segmentación: IoU por clase y ejemplos

Clase	IoU	Dice
Glioma	67.97 %	77.04 %

Meningioma	89.81 %	94.38 %
Hipófisis	80.48 %	88.12 %

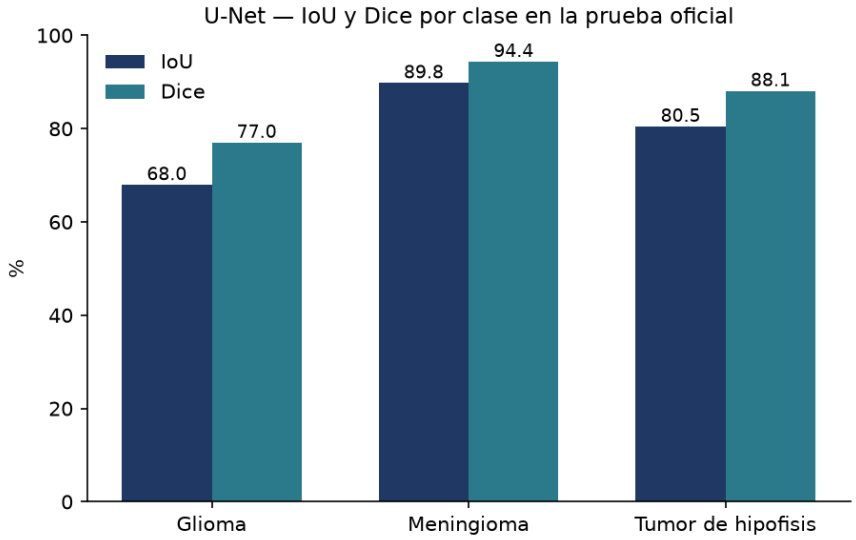


Figura 6. IoU y Dice por clase de tumor en la prueba. El glioma, de bajo contraste, es el más difícil de segmentar.

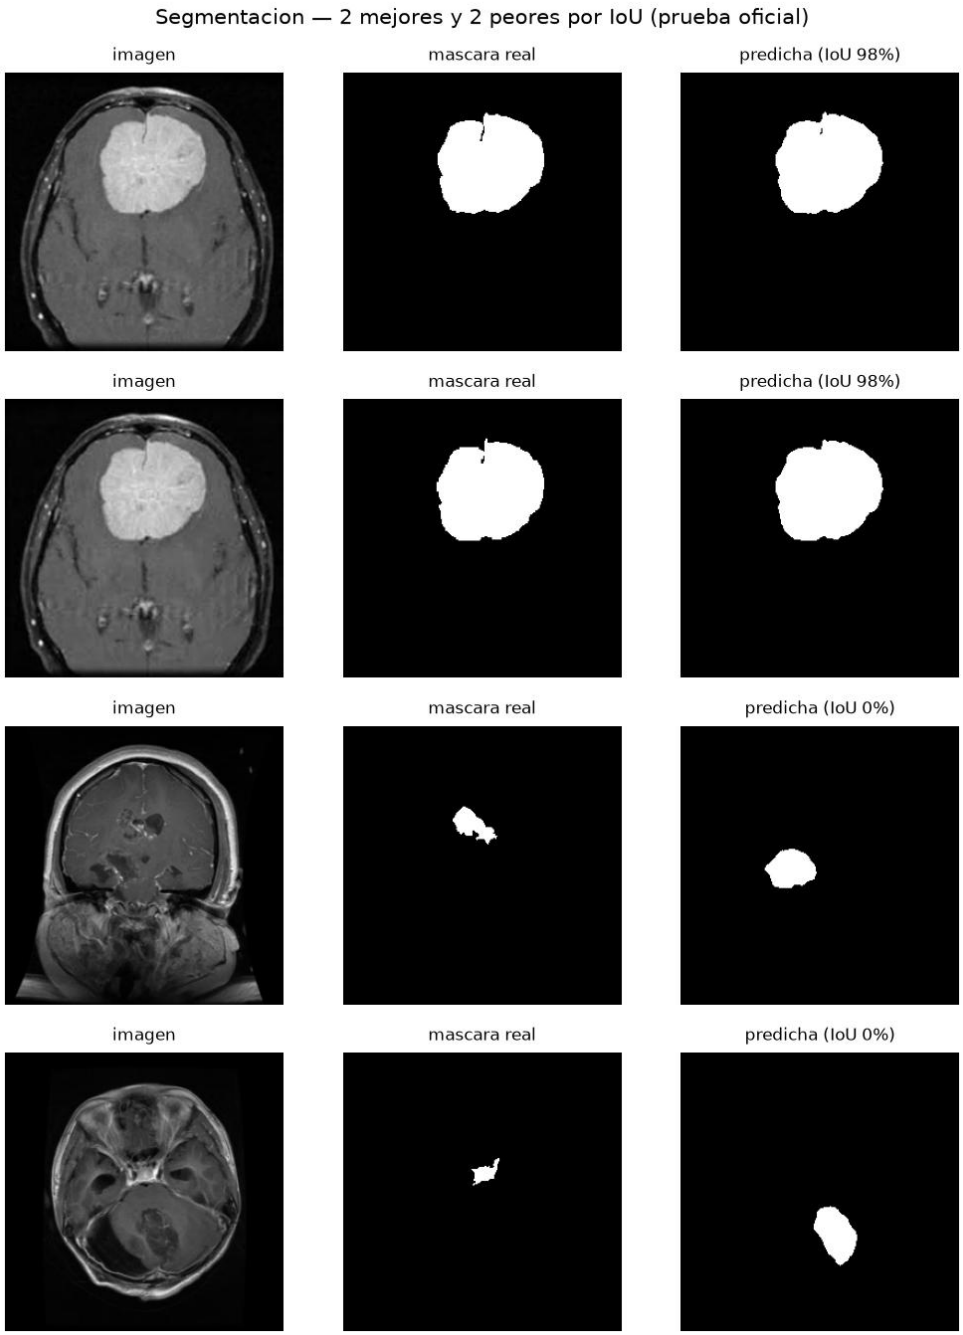


Figura 7. Segmentación real: 2 mejores y 2 peores por IoU. En los peores el modelo marca una región cercana pero no el tumor real (pequeño o desplazado).

5.4 Riesgo R09 (atajo por procedencia) y subconjunto sin fuga

Por tipo de archivo de origen (gris/RGB): accuracy 99.1 % (gris) frente a 99.0 % (RGB); IoU 78.9 % (gris) frente a 82.7 % (RGB). La brecha de la U-Net coincide con que el glioma —la clase más difícil— es mayoritariamente en gris.

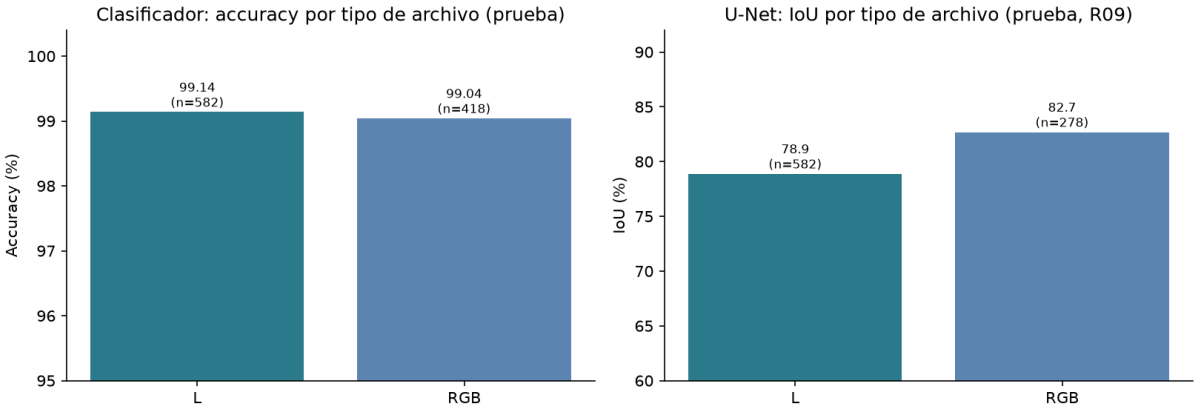


Figura 8. Desempeño por tipo de archivo de origen en la prueba oficial (riesgo R09).

Subconjunto sin vecino cercano: 196 de las 1.000 imágenes de prueba tienen un vecino casi idéntico en el entrenamiento oficial (correlación de miniaturas 32×32 ≥ 0,98). Quitándolas, el desempeño baja poco: accuracy 98.88 % (n=804) e IoU 78.43 % (n=665). El efecto de la fuga es pequeño.

6. Despliegue: la aplicación clínica (HU13)

El modelo se desplegó en un **prototipo de sistema clínico** con el flujo principal de apoyo al diagnóstico en neuro-oncología completo y los demás módulos como maqueta. Tecnología: FastAPI + Jinja2 + SQLite; inferencia con ONNX Runtime en CPU; **funciona sin internet** (fuentes del sistema, nada de CDN); diseño blanco y formal. Decisión de arquitectura (riesgo R05): backend local en vez de correr el modelo en el navegador, porque la U-Net pesa ~98 MB en ONNX.

Reglas de decisión: si el clasificador predice «sin tumor», no se muestra contorno (el segmentador solo se entrenó con imágenes con tumor); si la probabilidad más alta es < 80 %, se marca «confianza baja: requiere revisión»; se valida la entrada (PNG/JPG, brillo medio del cerebro en el rango de entrenamiento). El aviso de demostración aparece en todas las pantallas; la decisión final es siempre del médico.

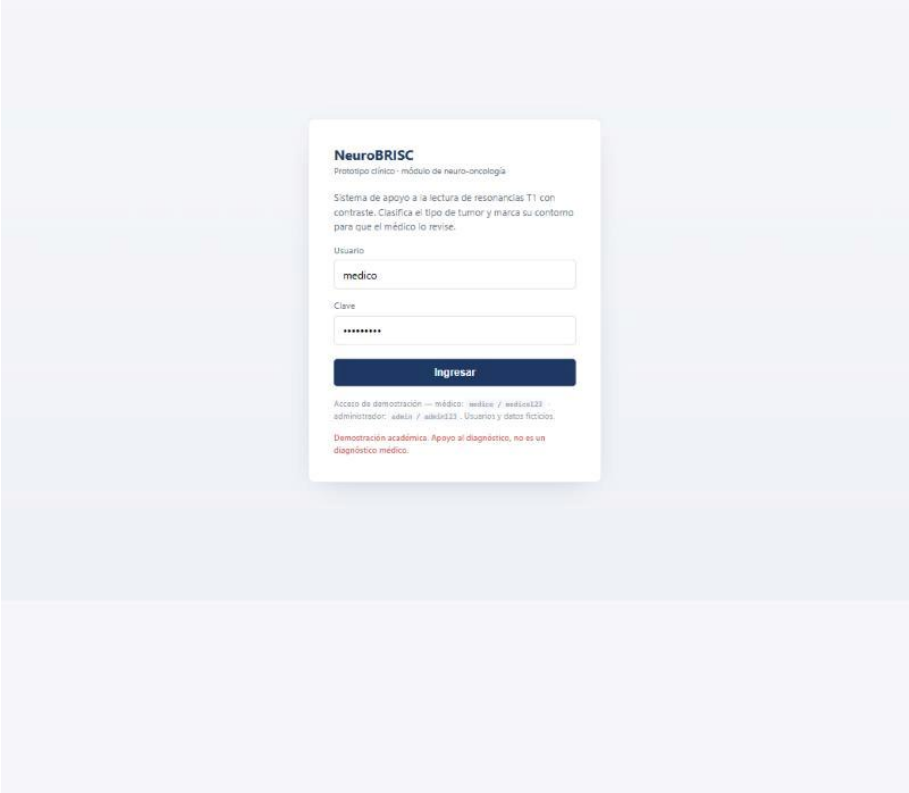


Figura 9. Inicio de sesión del prototipo (usuarios ficticios).

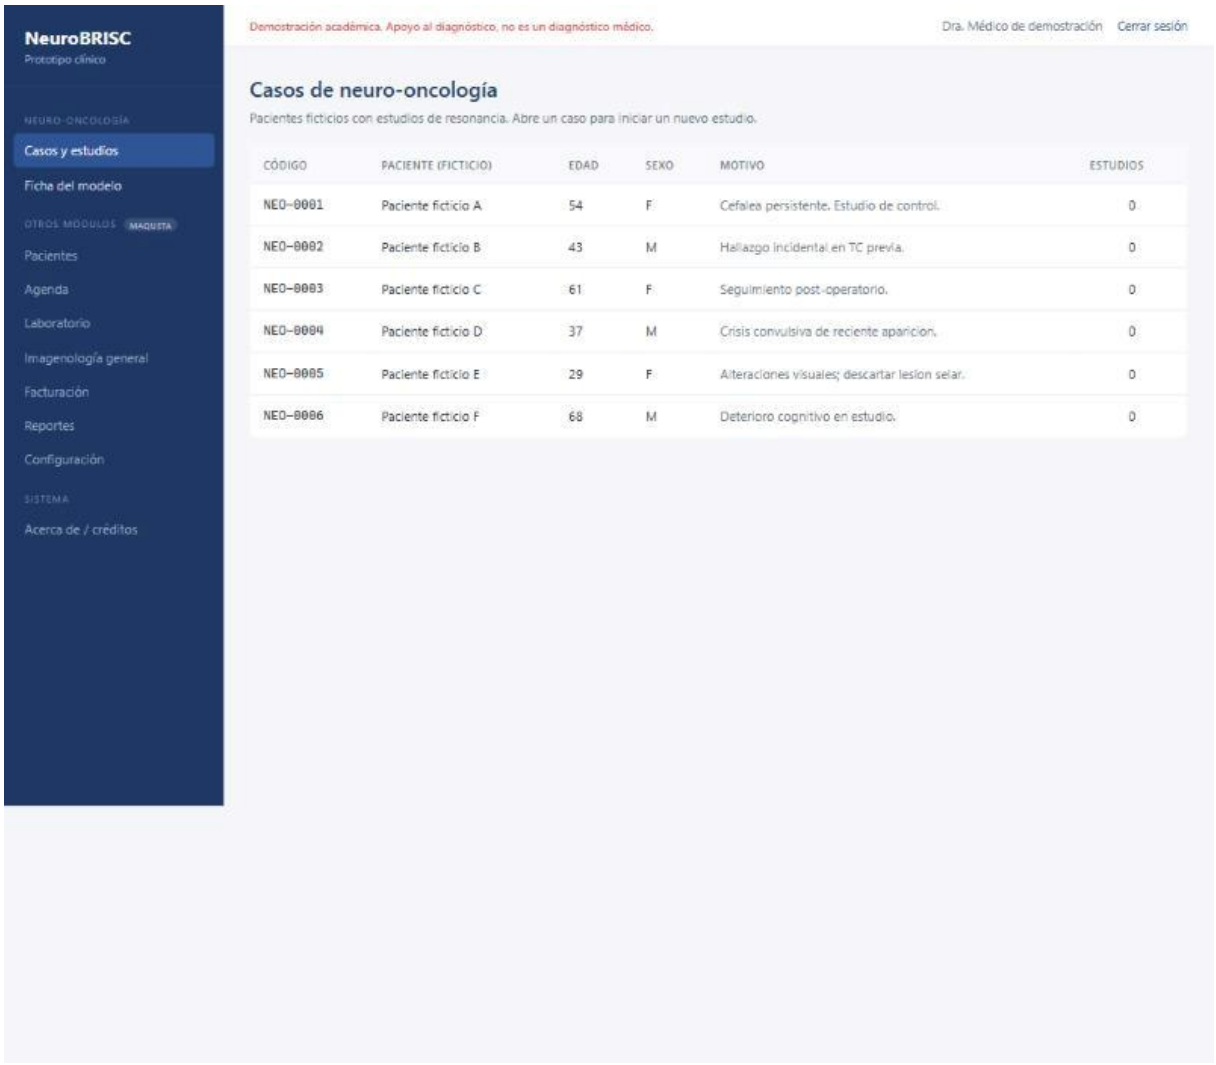


Figura 10. Lista de casos con pacientes ficticios (módulo de neuro-oncología).

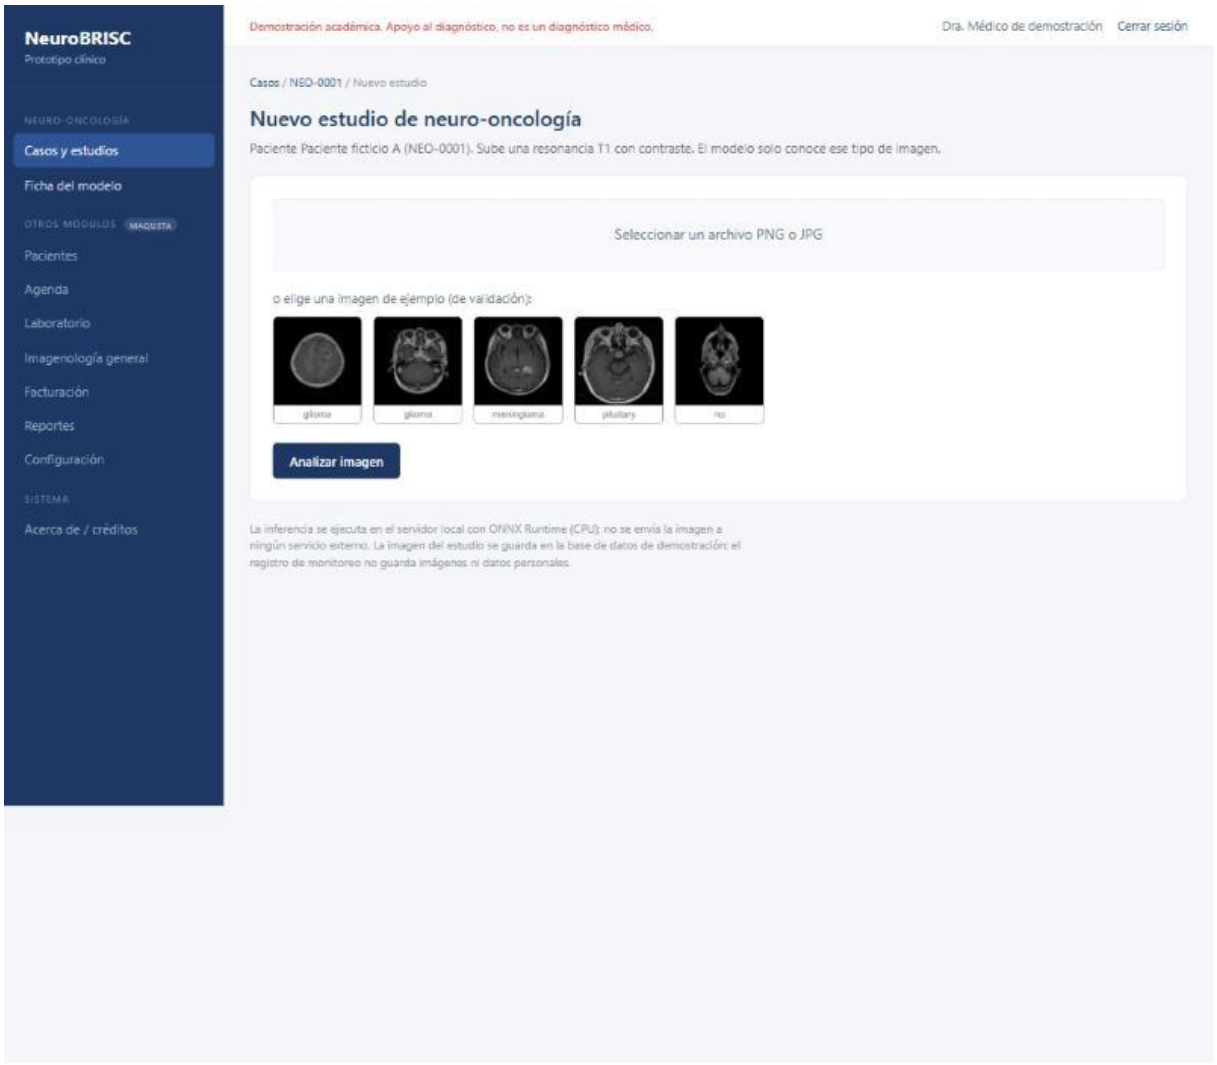


Figura 11. Nuevo estudio: subir una resonancia T1 o elegir un ejemplo de validación.

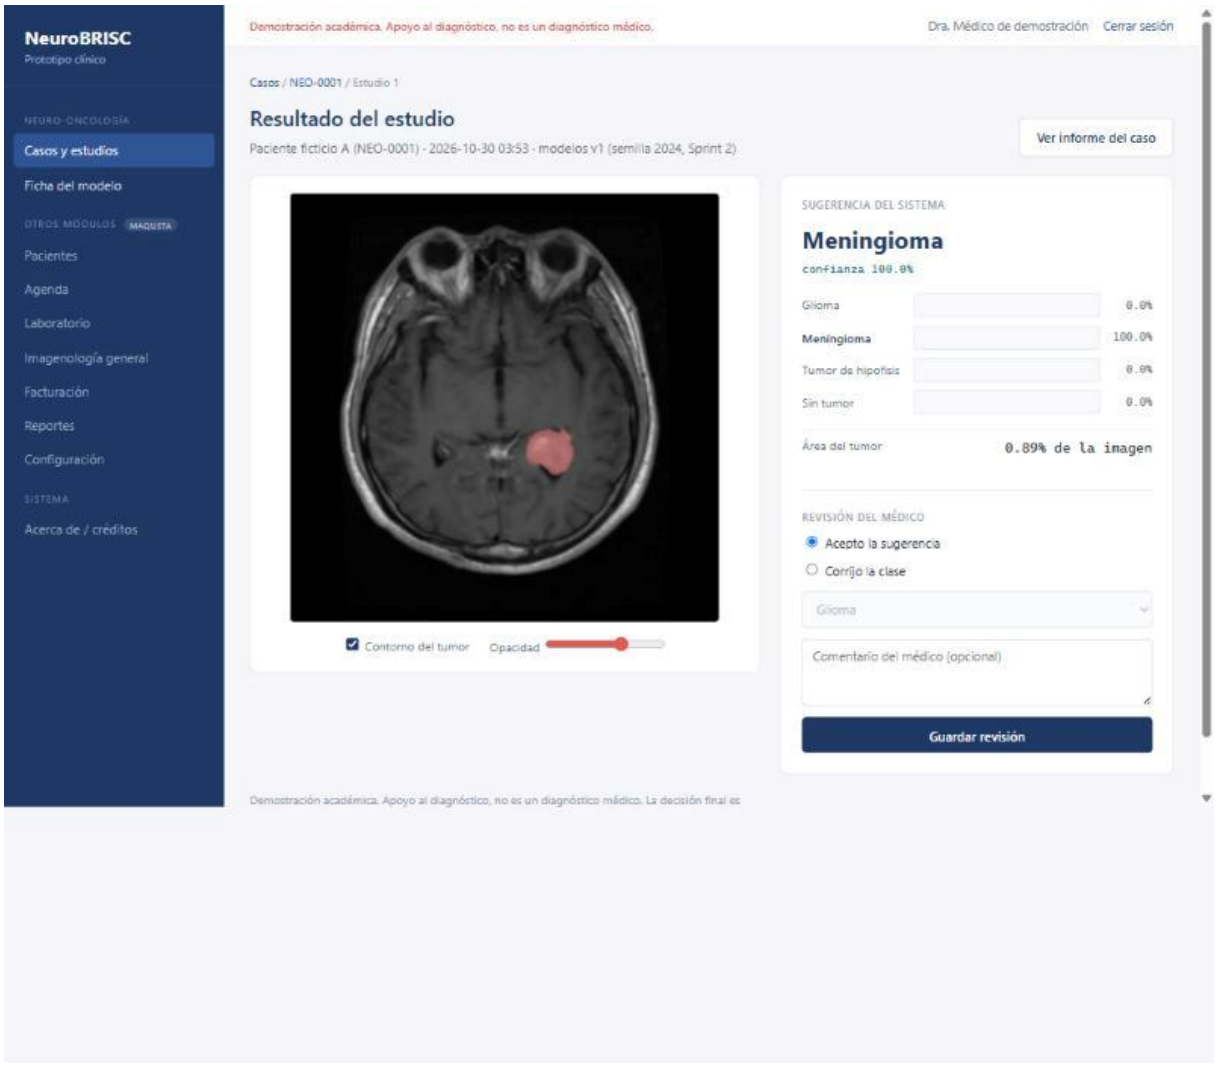


Figura 12. Resultado real: clase sugerida (Meningioma 100 %), probabilidades, contorno del tumor con control de opacidad, área, y el formulario de revisión del médico.

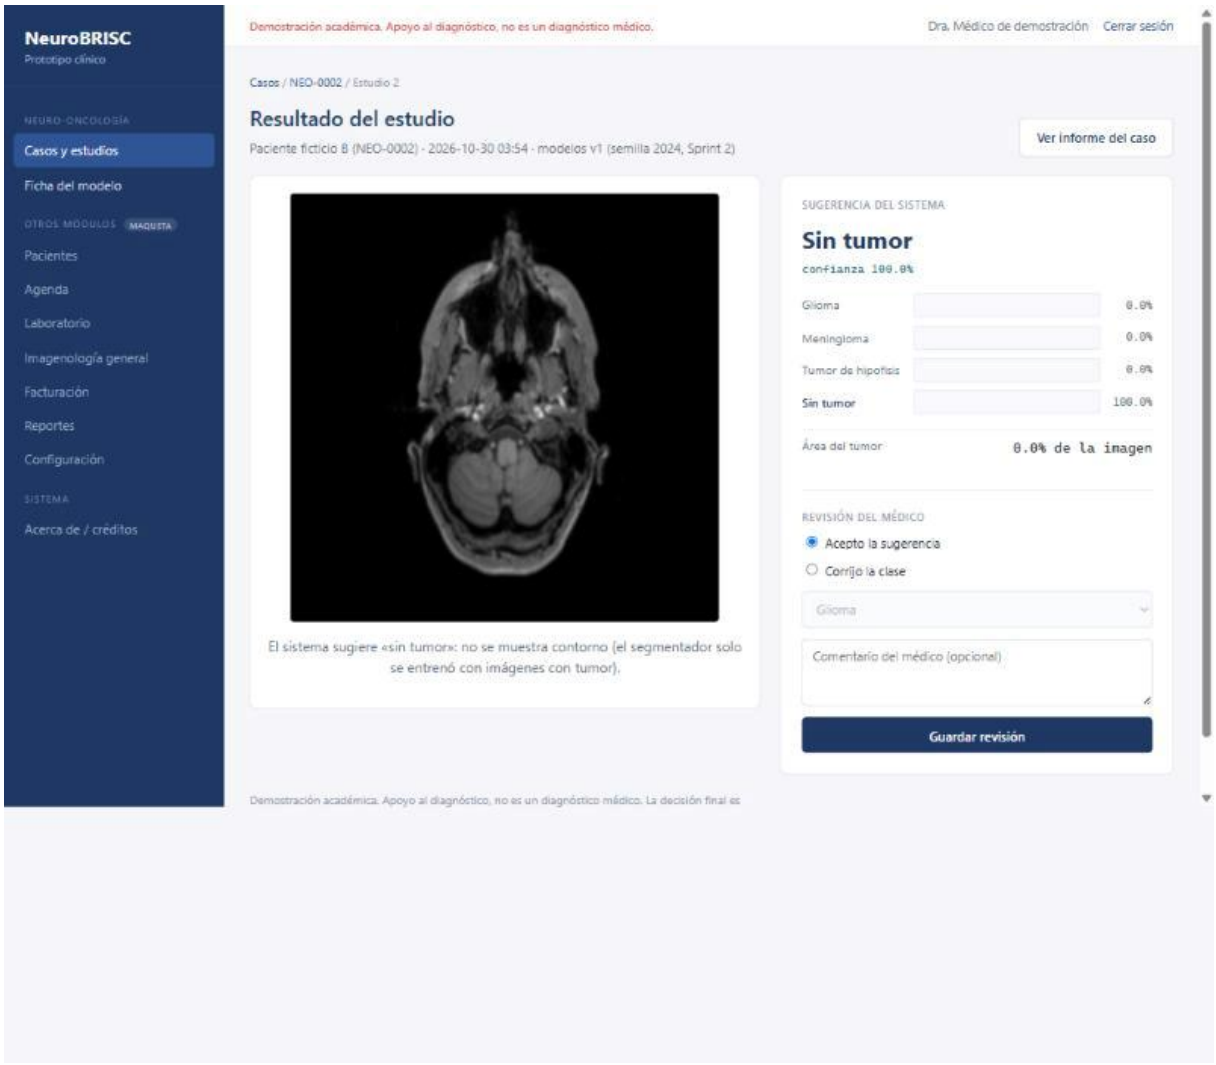


Figura 13. Caso «sin tumor»: el sistema no muestra contorno (regla de decisión).

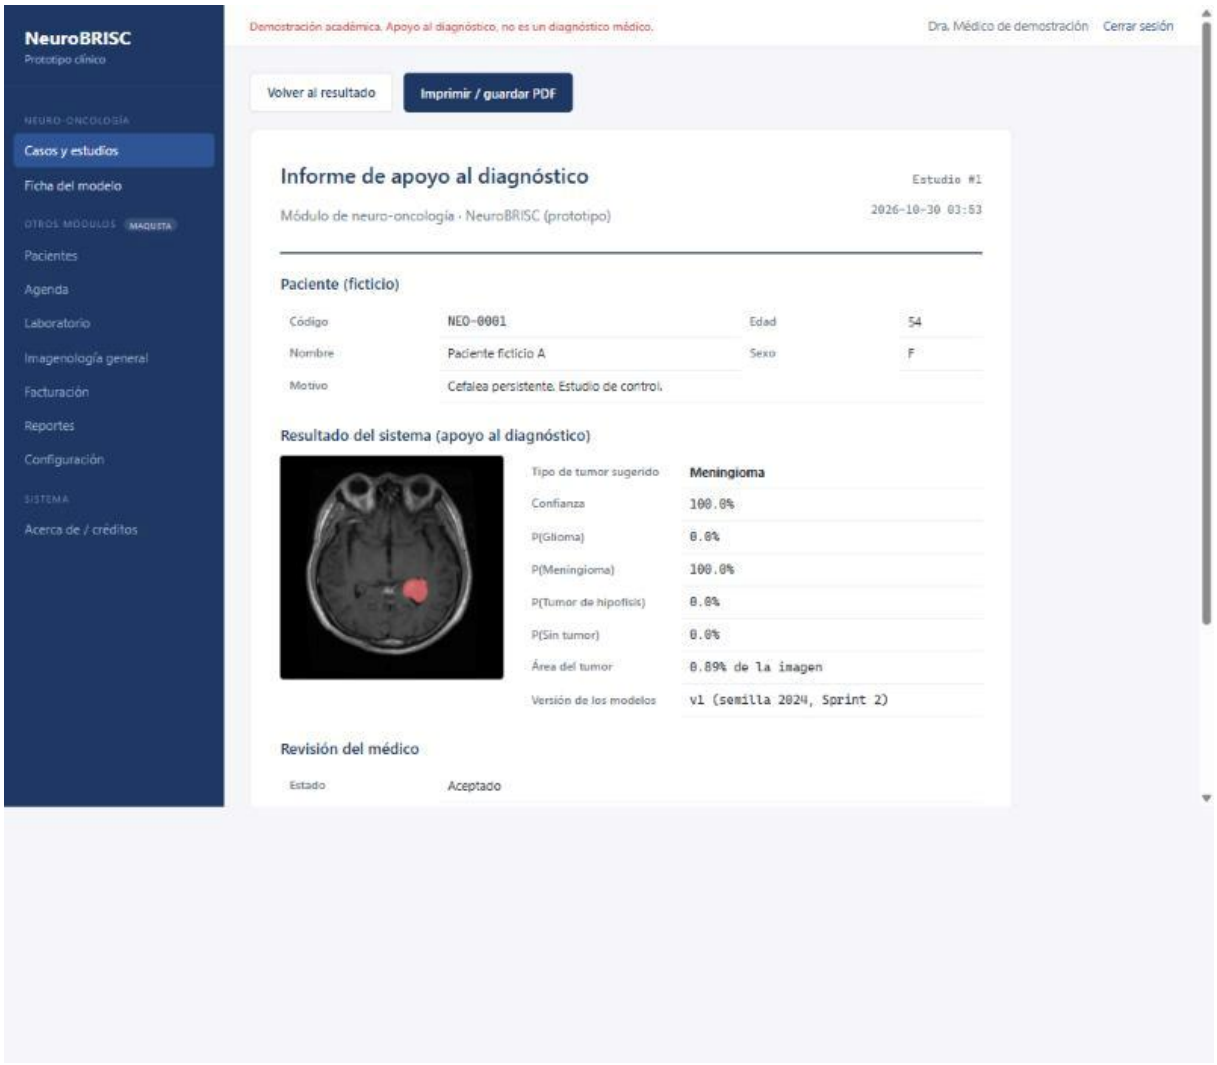


Figura 14. Informe del caso imprimible, con la versión de los modelos, la revisión del médico y el aviso de demostración.



Figura 15. Ficha de los modelos: métricas de validación y de la prueba oficial, uso previsto y limitaciones.

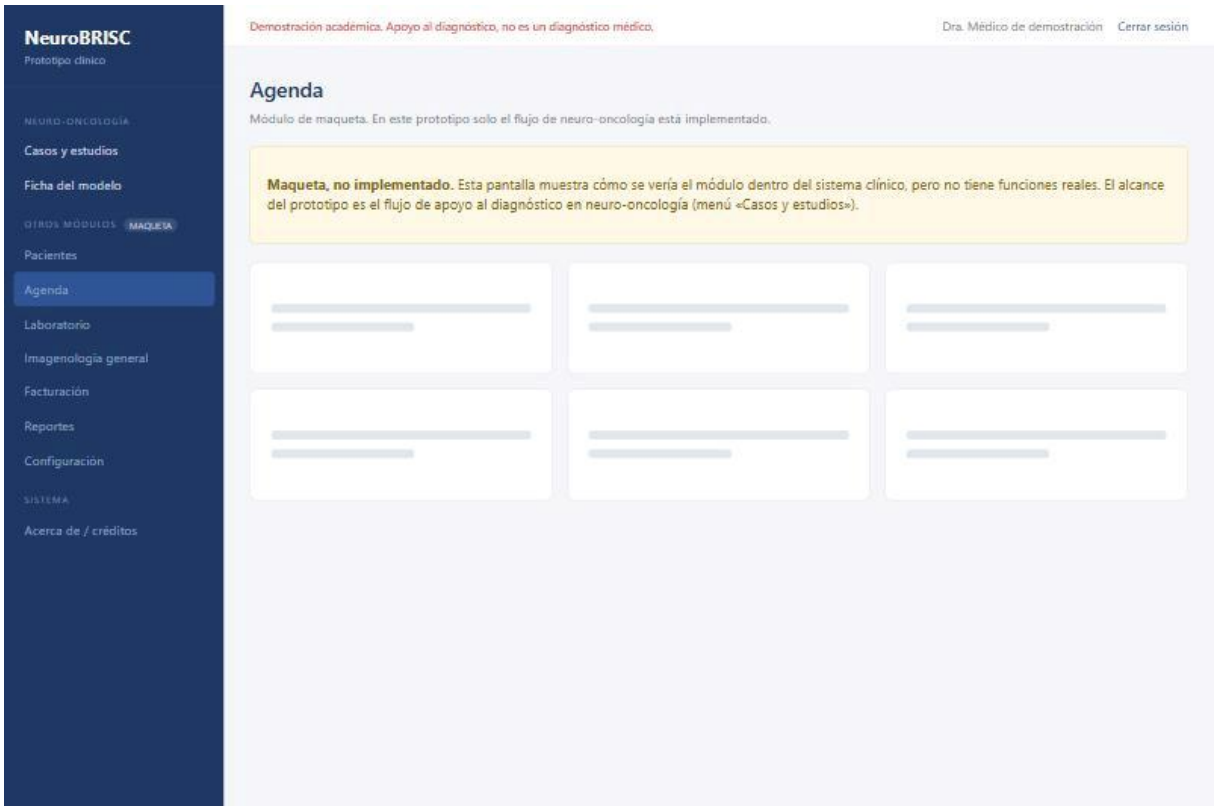


Figura 16. Los demás módulos son maqueta, marcados «no implementado».

7. MLOps básico (HU14)

- **Versionado de modelos:** cada modelo desplegado en ONNX (clasificador_v1 16 MB, segmentacion_v1 97,7 MB) con su tarjeta de modelo y **SHA-256**; paridad PyTorch↔ONNX verificada.
- **Registro de modelos y de datos:** `registro_modelos.json` reúne procedencia, SHA-256, métricas de validación y de prueba, la **versión del dataset** (SHA-256 del manifest + semilla 42), las versiones de las librerías y el **commit de Git** (7e19df8).
- **Etiquetas de Git** (versión identificable): datos-v1.0, modelo-clasificador-v1.0, modelo-segmentacion-v1.0, app-v1.0.
- **Monitoreo** en la aplicación (página de administrador): registra cada predicción (clase, probabilidades, confianza, área, tiempo de respuesta, brillo medio de la entrada y alerta de confianza baja) **sin guardar imágenes ni datos personales**; compara el brillo medio con el del entrenamiento como señal simple de deriva.

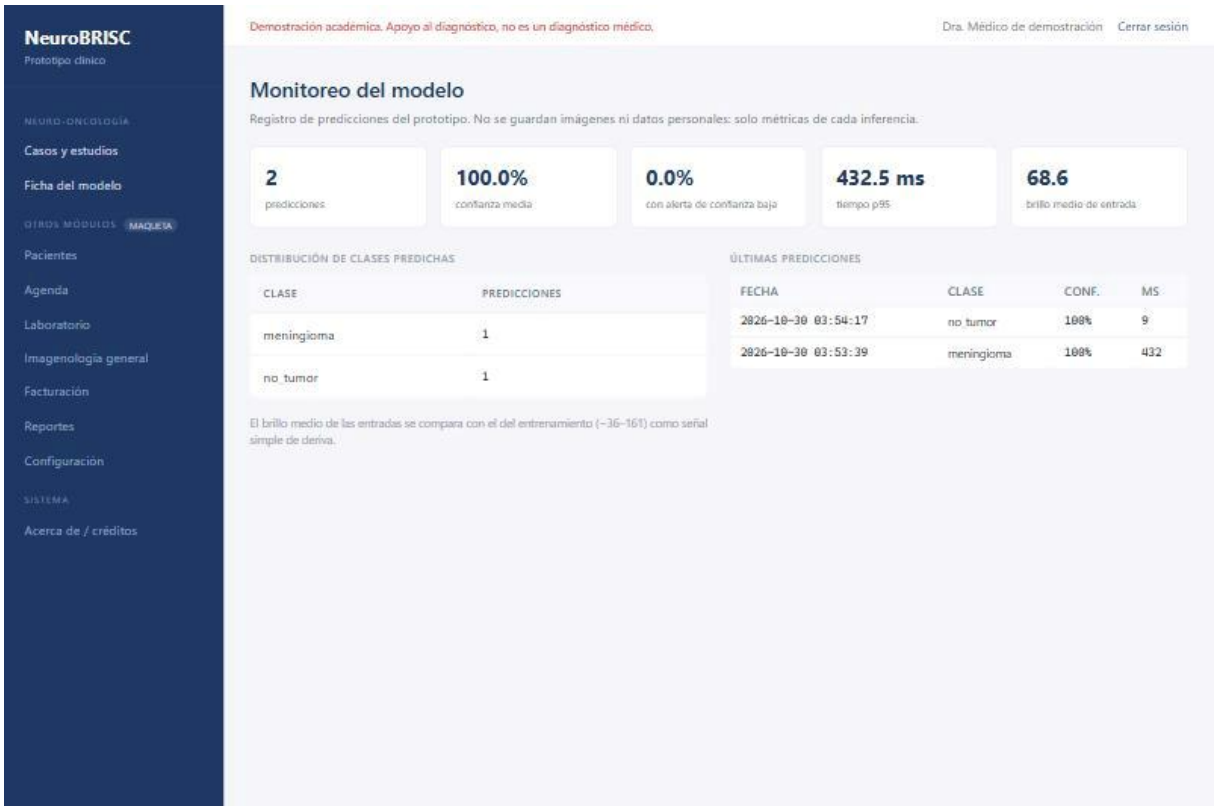


Figura 17. Página de monitoreo: total de predicciones, confianza media, porcentaje de alertas, tiempo p95 y distribución de clases.

Los pesos (.pt) y los modelos (.onnx) no se suben a Git; se regeneran con los scripts. Lo versionado es el código, las tarjetas de modelo y el registro de métricas.

8. Limitaciones y consideraciones éticas

- **La prueba se evaluó una sola vez** y el modelo desplegado se eligió por validación, no por la prueba.
- **Fuga:** 196 imágenes de prueba tienen un vecino casi idéntico en el entrenamiento; se reportan las métricas también sin ellas (el efecto es pequeño).
- **El glioma es la clase más difícil**, tanto en clasificación (menor recall) como en segmentación (menor IoU), por su bajo contraste con el tejido.
- **Un solo dataset y una sola secuencia** (T1 con contraste); no se probó la generalización a otros escáneres o secuencias. El dataset no tiene identificador de paciente.
- **Ética y privacidad:** es una demostración académica de **apoyo al diagnóstico**, no un diagnóstico y no sustituye al médico. Todo se procesa en local; no se usan datos de pacientes reales; el monitoreo no guarda imágenes ni datos personales. Se cita el dataset BRISC 2025 (CC BY 4.0).

9. Conclusiones y trabajo futuro

- El sistema cumple las tres metas del acta en la prueba oficial y se desplegó en un prototipo de apoyo al diagnóstico funcional, reproducible y versionado.
- Trabajo futuro: mejorar el glioma (más datos o pérdidas específicas), validar con otros datasets y escáneres, un modelo multitarea con encoder compartido, y pasos de MLOps más completos (reentrenamiento ante deriva).

10. Anexo

10.1 Revisión por el equipo (HU15)

Integrante	Rol	Revisión	Fecha
Coavoy Cruz Joseph Gabriel	Gerente de Proyecto	☐ revisado	____
Cuchuyrrumi Mamani Manuel Rodrigo	Scrum Master	☐ revisado	____
Huallpatuiro Rafaile Brayan	Desarrollo	☐ revisado	____
Mamani Acuña Frank Joseph	Desarrollo	☐ revisado	____

10.2 Glosario

ONNX: formato estándar para servir modelos sin PyTorch (aquí, con ONNX Runtime en CPU).

IoU / Dice: cuánto se solapa la máscara predicha con la real.

Recall: de los casos reales de una clase, cuántos detecta el modelo.

Transfer learning: partir de una red entrenada con otro dataset (ImageNet).

Fuga: que imágenes casi iguales caigan en entrenamiento y evaluación, inflando resultados.

MLOps: prácticas para versionar, desplegar y monitorear modelos de forma reproducible.